

Паралельная (не авторегрессионная) языковая модель

[https://github.com/awant/non autoregressive lm](https://github.com/awant/non_autoregressive_lm)

План

- Проблемы генерации текста, языковых моделей
- Постановка задачи
- Метрики
- Бейзлайн
- Эксперименты
- Выводы

Проблемы генерации текста

- Для текста пространство дискретно, а генерируемое латентное пространство - непрерывно
- Текст - последовательность с длинными зависимостями и сильными зависимостями каждого следующего слова от предыдущего
- Текст, как правило, генерируется последовательно (медленный инференс)
- Малая вариативность примеров. Проблема "ухода с пути" при генерации текста
- Сложность измерения качества полученного текста

Постановка задачи

- Определить метрики, характеризующие качество языковой модели
- Построить параллельную языковую модель, лишенную перечисленных недостатков
- Сравнить качество получившейся модели с бейзлайном
- Устранение прямых зависимостей между генерируемыми токенами
 - увеличивает разнообразие примеров
 - позволяет получать токены параллельно
 - может быть использовано как аналог beam search

Метрики

- Подсчет forward ppl, reverse ppl (меньше - лучше).
- Для подсчета perplexity выбрана хорошо известная языковая модель: **kenlm** (Kneser–Ney, <https://kheafield.com/code/kenlm/>)
- Обученная языковая модель: **model**
- В таком виде **forward ppl** показывает то, насколько генерируемые предложения адекватны, а **backward ppl** - их разнообразие (в случае backward ppl мы тренируем kenlm на сгенерированных предложениях и вычисляем ppl на реальных предложениях (oof sentences))

Forward ppl

model -> sentences

kenlm(sentences) -> ppl

Backward ppl


model -> sentences

train kenlm on sentences -> kenlm

kenlm(oof sentences) -> ppl

Бейзлайн


- За бейзлайн была выбрана авторегрессионная ARAE модель (<https://arxiv.org/abs/1706.04223>)
- ARAE модель обучается генерировать предложения из шума. Компоненты: Autoencoder, GANs.



Бейзлайн. ARAE

- Обучение модели (сети: encoder, decoder, generator, critic)
- Генератор учится отображать шум на распределение \mathbf{Z} (внутреннее представление текста)
- Критик / дискриминатор старается отличить реальный Z от сгенерированного Z

discrete (\mathbb{P}_\star) encoder code (\mathbb{P}_Q) decoder model (\mathbb{P}_ψ) reconst.




noise (\mathcal{N}, \dots) generator prior (\mathbb{P}_z) critic reg.

ParallRAE

- Вход декодера - вектор \mathbf{Z} , выход - распределение вероятностей токенов на каждой позиции
- Для получения параллельной модели из авторегрессионной выбрано несколько архитектур декодера:
 - Dense (своя Dense NNet сеть на каждое из позиций. Позиций - фиксированное количество)
 - Dense + PosEnc (добавление слоя Positional encoding - из архитектуры трансформера. суммирование/конкатенация)
 - Dense с добавлением индекса позиции (конкатенация)
 - Conv (convolutional NN)

Parallel Dense/PosEnc



Результаты

Model	Autoencoder Accuracy, %	Forward PPL	Reverse PPL
ARAE	93	44.3	82.2
Parall ARAE (Dense)	86	110	108
Parall ARAE (Dense, pos_idx)	87	113	105
Parall ARAE (Dense, Pos enc, sum)	86	108	103
Parall ARAE (Dense, Pos enc, concat)	91	94	97
Parall ARAE (Conv)	70	181	254

Примеры сгенерированных предложений

Модель:

Parall ARAE (Dense, Pos enc, concat)

Предложения:

the man is on a slide outdoors .

the couple is sharing the bat on his friends .

the people are sitting down a river .

an old girl is with a dog .

two people walking at the field .

Выводы

- Исследовано латентное пространство
- Реализована ARAE модель
- Выполнены эксперименты по параллельной генерации
- Выбрана лучшая архитектура
- Написание статьи (?)